

סיכום מטלת הבית

1. שלבי בניית הפרויקט

השלב הראשון בפרויקט לא היה כתיבת קוד, אלא הבנת הבעיה שאותה נדרשתי לפתור. מכיוון שלא היה לי ידע קודם בתחום הראייה הממוחשבת ועיבוד תמונה, הקדשתי זמן ללמידה, מחקר של אלגוריתמים קיימים והבנה של האתגרים הכרוכים בבניית מערכת מעקב. במהלך המחקר התברר שהקושי המרכזי בפרויקט הוא שהמערכת נדרשת ללמוד אובייקט שרירותי מתוך דוגמה אחת בלבד, ללא ידע מוקדם או מודל שאומן במיוחד עבורו. לאחר שהבנתי את אופי הבעיה, עברתי לחקור אילו מאפיינים ניתן להסיק מאובייקט בודד על מנת לזהות אותו מחדש. כבר בתחילת הדרך היה לי ברור שאין מאפיין יחיד שיכול לפתור את הבעיה באופן מלא. לכן, בחנתי מגוון רחב של מאפיינים אפשריים. במקביל, בחנתי יכולות של מנגנוני עקיבה מבוססים זיהוי אובייקטים, אך הוחלט שלא לבסס עליהם את המערכת, משום שהם מיועדים לזיהוי קטגוריות ידועות מראש. לאחר שלב המחקר גיבשתי תוכנית עבודה ראשונית ותכננתי את ארכיטקטורת המערכת. המטרה הייתה לבנות מערכת מודולרית, שבה לכל רכיב אחריות ברורה, כך שניתן יהיה להחליף או לשפר כל רכיב בנפרד מבלי להשפיע על שאר המערכת. בשלב זה תכננתי את רכיבי הליבה, כגון מנגנון המעקב, בניית פרופיל המטרה וזיכרון, זיהוי לאחר אובדן המטרה, חיפוש והתאוששות, מערכת הקונפיגורציה וכלי debug. בתחילת הפיתוח שקלתי להוסיף למערכת יכולות נוספות מעבר לדרישות המטלה, מתוך מחשבה להפוך אותה לעשירה יותר מבחינה פונקציונלית. לאחר מספר ימי עבודה, הבנתי שהצורך הגדול יותר הוא שיפור איכות המעקב, הדיוק ואמינות המערכת. הקדשתי את מרבית זמן הפיתוח לשיפור האלגוריתמים הקיימים, טיפול במקרי קצה והגדלת אחוזי ההצלחה של המערכת. לאחר בניית התשתית הראשונית, פיתחתי מערכת המבוססת על Trackers של OpenCV כגון CSRT, KCF ו-MOSSE. במהלך סדרת הניסויים התגלו מגבלות משמעותיות, בעיקר במקרים של שינויי קנה מידה קיצוניים ואובדן המטרה. בעקבות תוצאות אלו בחנתי במקביל Trackers יותר מתקדמים, כגון ViT ו-NanoTrack, למרות שהם הציגו ביצועים טובים יותר במצבים מסוימים, הניסויים הראו שגם להם קיימות מגבלות, בעיקר כאשר האובייקט קטן מאוד, או שקשה להבחין בינו לבין אובייקטים דומים אחרים. לכן הוחלט שלא להסתמך על Tracker יחיד, אלא לשלב את יתרונותיהם במסגרת ארכיטקטורה היברידית. המערכת הסופית מפרידה בין שלוש שאלות מרכזיות: היכן נמצא האובייקט (Center), מהו גודלו הנוכחי (Scale), והאם מדובר באמת באותו אובייקט (Identity). מיקום מרכז האובייקט מתקבל בעיקר

באמצעות TrackerViT, שנבחר בזכות יכולתו לעקוב אחר אובייקטים שרירותיים בצורה יציבה גם ללא סיווג סמנטי. שינויי הגודל מחושבים באמצעות Optical Flow בשילוב RANSAC, המספקים הערכה גאומטרית של שינוי קנה המידה בין פריימים ומתמודדים טוב יותר עם התקרבות או התרחקות של המצלמה. לבסוף, אימות הזהות מתבצע באמצעות Appearance Verification, המבוסס על שילוב של רמזים חזותיים משלימים – התאמת תבניות (NCC), השוואת היסטוגרמות צבע במרחב (HSV), והתאמת נקודות עניין באמצעות ORB. שילוב זה מאפשר להימנע מתלות במאפיין יחיד, ומספק הערכת ביטחון יציבה יותר לפני קבלת החלטות כגון הכרזה על אובדן המטרה או רכישה מחדש. לאורך כל הפרויקט עבדתי בגישה ניסויית. כל שינוי במערכת לווה בהרצה של מספר תרחישים וצפייה בסרטוני הפלט, והשוואה לגרסאות קודמות. בהתאם לממצאים בוצע כוונן של ערכי הסף בקובץ הקונפיגורציה, שופרו מנגנוני קבלת ההחלטות ולעיתים אף בוטלו שינויים שלא הובילו לשינוי עקבי. כבר בשלבים הראשונים היה לי ברור שמערכת כזו מקבלת בכל פריים מספר רב של החלטות שקשה להבין באמצעות קריאת הקוד בלבד או צפייה בסרטוני הפלט. קשה להבין מדוע המערכת בחרה באובייקט מסוים או מדוע הכריזה על אובדן המטרה. כיוון שהתחום היה חדש עבורי, היה לי חשוב שלא להסתמך רק על ההבנה התאורטית שרכשתי במהלך המחקר, אלא לבנות כלים שיאפשרו לי לראות את תהליך החשיבה בפועל ולהסיק מסקנות. לכן הוספתי דיבוג ויזואלי שמציג בזמן אמת את המועמדים שנמצאו בכל פריים בזמן שהמערכת במצב חיפוש, ורמת הביטחון לבחירה בכל מועמד. כך יכולתי להבין בכל שלב כיצד המערכת "חשבה", לזהות נקודות כשל, לכוון ערכי סף, להשוות בין גרסאות שונות של האלגוריתם ולקבל החלטות המבוססות על התנהגות המערכת בפועל.

2. העקרונות המנחים בפיתוח

- מודולריות והפרדת אחריות – חילקתי את המערכת לרכיבים עצמאיים, כאשר לכל אחד אחריות מוגדרת וברורה. גישה זו מאפשרת לי להחליף או לשפר כל רכיב באופן עצמאי, לבצע ניסויים בצורה מבוקרת ולהימנע מהשפעה מיותרת על שאר חלקי המערכת.
- פירוק הבעיה – במהלך הפיתוח הבנתי שמערכת כזו מורכבת ממספר שאלות שונות כפי שציינתי לפני כן, ולכן בחרתי לבנות מערכת שבה כל רכיב מתמחה בפתרון בעיה אחת, במקום להעמיס את כל האחריות על מנגנון המעקב בלבד.
- יכולת הסבר – היה לי חשוב לבנות מערכת שתדע להסביר את עצמה ואת תהליך קבלת ההחלטות שלה, כך אוכל להיעזר בה כדי להבין טוב יותר את כוונן ההגדרות וקביעת ערכי הסף, גם אם אני לא מבין עד הסוף את המשמעות של כל אחד מהם.

- ביצועים – המערכת תוכננה לרוץ על מעבד בלבד, ללא תלות בכרטיס גרפי. לשם כך עיבוד הסרטון מתבצע באופן סדרתי, פריים אחר פריים, מבלי לטעון את כל הסרטון לזיכרון. בנוסף, האלגוריתמים היקרים מבחינה חישובית מופעלים רק כאשר הם באמת נדרשים.
- פיתוח מונחה ניסויים – החלטות הנדסיות לא התקבלו על סמך תחושת בטן בלבד, אלא לאחר השוואת תוצאות בין גרסאות שונות של המערכת.
- איזון בין מורכבות לתועלת – בחנתי מספר אלגוריתמים ורעיונות מתקדים, אך לא כל אחד מהם שולב במערכת הסופית. הוספתי מורכבות רק כאשר היא סיפקה שיפור ממשי ומדיד. אם תוספת מסוימת לא הצדיקה את המחיר מבחינת ביצועים או יציבות, העדפתי לחזור לפתרון פשוט יותר.
- נכונות לעומת מדדים – העדפתי לצמצם כמה שיותר מעקב אחר אובייקט שגוי, גם במחיר של הכרזה מוקדמת על אובדן המטרה ורכישה מחדש. הפרופיל הראשוני נבנה על סמך דוגמה בודדת מהפריים הראשון, העדפתי שהמערכת לא תקבל החלטות מהותיות כאשר רמת הביטחון אינה מספקת. בנוסף, השתדלתי להימנע מ- overfitting לסרטוני הבדיקה. כל שינוי נבחן על מספר תרחישים שונים, ורק שיפורים שהציגו התנהגות עקבית ולא פתרו מקרה נקודתי בלבד שולבו במערכת הסופית.

3. אלגוריתמים ומדדים שחקרתי והמסקנות

- CSRT – אחד ממנגנוני המעקב הנפוצים והמדויקים של OpenCV. מחשב התאמה בין ייצוג האובייקט לבין אזור החיפוש בפריים הנוכחי. הציג יציבות טובה במצבי מעקב רגילים, התקשה במקרים של שינוי קנה מידה והבדלה בין אובייקטים דומים. בסיס מצוין למערכת, אינו מספיק כפתרון עצמאי.
- KCF – משתמש ב- kernel trick כדי לחשב התאמות במרחב מאפיינים במימד גבוה. ומתאים במיוחד למערכות זמן אמת. עם זאת, רגיש מאוד לשינוי קנה מידה ואינו מתמודד היטב עם אובדן המטרה. הביצועים שלו לא הצדיקו שימוש כפתרון מרכזי.
- MOSSE – מבוסס על מזעור שגיאת ההתאמה בין המטרה לבין אזור החיפוש. נבחן כחלופה קלת משקל, מהיר מאוד גם על חומרה בסיסית. רמת הדיוק שלו הייתה הנמוכה ביותר ביחס לשאר האלגוריתמים ולכן לא התאים לדרישות הפרויקט.
- NanoTrack – מבוסס על רשת נוירונים בסיסים הלומדת להשוות בין המטרה הראשונית לתמונה הנוכחית. הציג שיפור מועט, עדיין התקשה במקרי קצה ובשינויי מראה משמעותיים. היווה שיפור, אך לא פתר את הבעיה לבדו.
- TrackerViT – מבוסס על ייצוג וקטורי של התבנית ואזור החיפוש, המאפשר ללמוד ייצוג חזותי עשיר יותר של האובייקט. הציג יציבות טובה יותר במעקב אחר אובייקטים שרירותיים, אך עדיין עלול

להיסחף ולהינעל על אובייקטים דומים ללא מנגנון אימות נוסף. שולב כחלק המרכזי במערכת היברידית, ולא כפתרון יחיד.

- NCC – מדד לדמיון בין תבניות, יעיל כאשר מבנה האובייקט נשמר. רגיש לשינוי בקנה מידה, סיבובים וזוויות. שולב כמדד במנגנון אימות הזהות.
 - HSV – משווה את התפלגות הצבעים של האובייקט. עמיד לשינויים קטנים בצורה, מושפע משינויי תאורה ואובייקטים בעלי צבעים דומים. מספק מידע משלים לזיהוי הפרופיל.
 - ORB – מבוסס על נקודות עניין ותיאורים בינאריים. יעיל על אובייקטים על מרקם מורכב, מתקשה עם אובייקטים ללא מאפיינים ייחודיים. שולב כאימות נוסף, אך לא מתאים לכל סוגי האובייקטים.
 - LK Optical Flow – מספק הערכה יעילה של תנועת האובייקט ושינוי המיקום שלו, קל יחסית מבחינה חישובית ומתאים לעבודה בזמן אמת על CPU. סיפק בסיס טוב להערכת התנועה, אך דרש מנגנון נוסף לסינון התאמות שגויות.
 - RANSAC – שימש לסינון התאמות שגויות של ה- Optical Flow. השילוב של שניהם היה יציב ומדויק יותר מהסתמכות על ה- Scale של ה- Tracker בלבד במקרים של תנועת מצלמה או שינוי מהותי במרחק.
 - YOLO – נבחן בתחילת המחקר, מתאים לזיהוי קטגוריות ידועות מראש. אינו מתאים למעקב אחר אובייקט שרירותי שנבחר בזמן אמת, ולכן נפסל כבסיס למערכת.
 - Appearance Embeddings – נבחנו לצורך שיפור זיהוי הזהות באמצעות ייצוג חזותי עמוק של האובייקט. הוסיפו מורכבות חישובית ולא סיפקו שיפור עקבי, ולכן הוסרו מהמערכת הסופית.
 - Ego-Motion Compensation – נבחן במטרה לפצות על תנועת המצלמה. שיפר חלק מהתרחישים, אך גרם לרגרסיות באחרים, ולכן לא שולב בגרסה הסופית.
- המסקנה הכללית היא שאין אלגוריתם יחיד שמסוגל להתמודד היטב עם כל סוגי האובייקטים ומקרי הקצה. אין מאפיין חזותי יחיד שמסוגל לזהות אובייקט באופן אמין בכל תנאי הסביבה. כל אלגוריתם שנבחן הצטיין בתרחישים מסוימים ונכשל באחרים. המסקנה המרכזית הייתה שהדרך הנכונה להתמודד עם הבעיה היא ארכיטקטורה היברידית שבה כל רכיב מטפל בהיבט אחר של המעקב (מיקום, קנה מידה, זהות והתאוששות), במקום להסתמך על אלגוריתם יחיד.

4. האתגר המרכזי בפרויקט והתמודדות

בתחילת העבודה הייתי בטוח שהאתגר המרכזי יהיה למצוא אלגוריתם מעקב טוב, שיוכל לעקוב אחרי האובייקט לאורך כל הסרטון. לאחר מספר ימי עבודה וניסויים הבנתי שהבעיה האמיתית מורכבת הרבה יותר. מרבית ה- Trackers מסוגלים לעקוב אחרי אובייקט כל עוד הוא נראה בבירור, אך כאשר הוא

משתנה, מוסתר חלקית או נעלם, הקושי האמיתי הוא לא למצוא אותו מחדש, אלא לקבוע אם האובייקט שנמצא הוא באמת אותו אחד שנבחר בתחילת הסרטון.

בניגוד למערכות זיהוי אובייקטים המבוססות על קטגוריות ידועות מראש, בפרויקט זה המערכת מקבלת דוגמה אחת בלבד של האובייקט בזמן הריצה. לכן אין למערכת מידע מוקדם על האובייקט, אין מאגר תמונות ואין מודל שאומן במיוחד עבורו. כל החלטה מתקבלת על סמך הפרופיל שנבנה מאותה דוגמה ראשונית, כאשר המראה של האובייקט עשוי להשתנות לאורך הסרטון.

במהלך הפיתוח ניסיתי מספר רב של גישות לשיפור המעקב והרכישה מחדש. במקרים רבים גיליתי שפתרון שנראה מבטיח מבחינה תאורטית לא סיפק שיפור עקבי בפועל, ולעיתים אף פגע בביצועי המערכת. במהלך הפרויקט למדתי שגם החלטה להסיר רכיב או לחזור לגרסה קודמת היא לעיתים החלטה הנדסית נכונה, אם היא מובילה למערכת יציבה ופשוטה יותר.

התובנה המרכזית שאליה הגעתי הייתה שאין אלגוריתם יחיד שמסוגל להתמודד עם כל מקרי הקצה. במקום להמשיך ולחפש אלגוריתם טוב יותר, בחרתי לשנות את אופן החשיבה ולפרק את הבעיה למספר בעיות קטנות יותר: הערכת מיקום האובייקט, הערכת שינוי קנה המידה, אימות הזהות, זיהוי אובדן המטרה ורכישה מחדש. עבור כל אחת מהבעיות נבחר האלגוריתם שהציג את הביצועים הטובים ביותר בניסויים, ומתוכם נבנתה הארכיטקטורה ההיברידית של המערכת.

בדיעבד הבנתי שהאתגר המרכזי בפרויקט לא היה לבנות מערכת שיודעת לעקוב אחר אובייקטים, אלא לבנות מערכת שיודעת מתי היא כבר אינה יכולה לסמוך על עצמה. אני רואה בתובנה זו את אחד הלקחים ההנדסיים החשובים ביותר שלמדתי במהלך הפרויקט.

מעבר לאתגר הטכני של הפרויקט עצמו, עבורי היה זה גם אתגר לימודי משמעותי. התחלתי את הפרויקט ללא רקע קודם בראייה ממוחשבת ובעיבוד תמונה, ולכן נדרשתי ללמוד תחום חדש כמעט מאפס, תוך כדי פיתוח המערכת. מצד אחד חקרתי את התאוריה שמאחורי האלגוריתמים והספריות השונות, ומצד שני יישמתי אותם בפועל, הסקתי מסקנות וחזרתי שוב ללמידה ולשיפור המערכת.

5. מגבלות המערכת

תחילה, רוב תהליך הכוונון והניסויים בוצעו על סרטון מרכזי יחיד שסופק עם המטלה. לדעתי, זה לא מספיק כדי להבטיח כוונון אופטימלי של כל הפרמטרים עבור המקרה הכללי. לכן ייתכן שעבור סרטונים שונים יהיה צורך בקונפיגורציה שונה וערכי סף שונים.

המגבלה המשמעותית ביותר שנצפתה במהלך הפיתוח הייתה יכולת הרכישה מחדש. המערכת התקשתה להבדיל בין מטרת המעקב לבין אובייקטים בעלי מאפיינים חזותיים דומים, בעיקר כאשר לא היה מועמד אחד שסף הביטחון עבורו היה גבוה משמעותית משאר המועמדים. כאשר ניסיתי גם להוריד

את ספי הביטחון כדי להגדיל את מספר הרכישות המוצלחות, הדבר הוביל לעלייה משמעותית במספר ה- False Positives ולרוב המערכת ננעלה על אזורי חול או על עצמים אחרים שדמו לפרופיל המטרה. בנוסף, המערכת מאוד רגישה לשינויים בבחירת האובייקט בפריים הראשון. תזוזה של פיקסל בודד ממרכז המטרה הראשונית בנה פרופיל שונה לגמרי והוביל להתנהגות שונה לחלוטין של המערכת לאורך הסרטון.

המערכת מאוד מוגבלת מבחינת חומרה וביצועים. במהלך המעקב הרגיל, הביצועים טובים יחסית, אך כאשר המטרה אבדה מופעלים אלגוריתמים נוספים לצורך שחזור מחדש. שלב זה מהווה את צוואר הבקבוק המרכזי של המערכת, וניתן לראות בבירור ירידה ב- FPS בזמן שהמערכת נמצאת במצב חיפוש. שימוש ב- GPU יכול לאפשר שילוב של מודלים מתקדמים מבוססים רשתות נוירונים, או אלגוריתמים כבדים יותר שיכולים לשמור על קצב העיבוד.

6. חוויה אישית

המטלה הייתה עבורי אחת מחוויות הלמידה המשמעותיות ביותר במהלך התואר. זהו תחום שלא יצא לי לעסוק בו במסגרת הלימודים, ולא היה לי כל רקע קודם בראייה ממוחשבת או בעיבוד תמונה. מעבר לידע הטכני שרכשתי, העבודה שינתה את הדרך שבה אני ניגש לבעיות הנדסיות. הבנתי את החשיבות של קבלת החלטות המבוססות על ניסויים, ניתוח תוצאות ובחינה ביקורתית של כל שינוי, ולא על הנחות מוקדמות בלבד.

במהלך הפרויקט נעזרתי בכלי AI כחלק מתהליך העבודה, לצורך מחקר, סקירת ספריות ואלגוריתמים, דיון בחלופות ארכיטקטוניות וביצוע ביקורות קוד. העבודה בצורה זו חידדה עבורי את ההבנה שכלים אלו אמנם מאיצים את תהליך הפיתוח, אבל אין תחליף לבדיקות והסקת מסקנות אמיתיות. בנוסף, היא חיזקה אצלי את ההבנה שאין פתרון מושלם, אלא אוסף של פשרות, כאשר לכל החלטה יש יתרונות וחסרונות. הוא לימד אותי לחשוב בצורה רחבה, מערכתית, שקולה ובוגרת. הלקח החשוב ביותר שלקחתי הוא היכולת להעביר ביקורת על עצמי. למדתי שלא צריך לחשוש לשנות כיוון, להסיר פתרונות שלא הוכיחו את עצמם, ואף לחזור אחורה כאשר התוצאות הראו שזו ההחלטה הנכונה. מבחינתי, זו הייתה לא רק חוויה של פיתוח תוכנה, אלא גם תהליך משמעותי של התבגרות מקצועית.